

Proyecto Integrador de Análisis de Datos **(CRISP-DM)**

PROYECTO POR:

LUIS CULAJAY
KAREN MORALES
BRANDON PORTILLO
JHONATAN SIMÓN

Grupo 3

PROYECTO INTEGRADOR DE ANÁLISIS DE DATOS (CRISP-DM)

- Business Understanding
- Data Understanding
- Data Preparation
- Modeling (Modelo en Estrella)
- Evaluation
- Deployment (Dashboard)



Grupo 3



Karen Morales
Data Administrator



Luis Culajay
Data Engineer



Jhonatan Simon
BI Analyst



Brandon Portillo
Data Analyst



Business Understanding

- KPI's Iniciales
- Canvas Data Product
- Requerimientos analiticos
- Preguntas de negocio

KPI's Iniciales

1

Tipo de distribución por retrasos

2

Vuelos Programados vs real (llegada)

3

Vuelos Programados vs real (salida)

4

Ranking de aerolineas puntuales

5

Porcentaje de cancelación

Preguntas de negocio

¿Qué aerolíneas y aeropuertos presentan mejor o peor puntualidad?

¿Cuáles son las causas de demora más relevantes y cómo se distribuyen por aerolínea/aeropuerto?

¿Qué rutas son más vulnerables a retrasos, cancelaciones o desvíos?

¿Qué tan diferentes son los tiempos programados vs reales y qué factores influyen en esa brecha?

¿Qué aeropuertos con mayor concurrencia muestran congestión operacional?

¿Las rutas largas tienen mejor o peor puntualidad que las rutas cortas?



Canvas Data Product

Problema	Datos	Solución	KPI's	Acciones	
<ul style="list-style-type: none"> Se desconoce qué aerolíneas presentan mejor o peor desempeño en puntualidad. No se sabe qué causas de demora son más frecuentes o relevantes. No está claro cuáles aeropuertos y rutas concentran mayor tráfico y riesgo operativo. Las cancelaciones y desvíos impactan la eficiencia del sistema y requieren identificación. 	Se tiene un dataset de Bureau of Transportation Statistics (BTS) que contiene horarios, retrasos, causas de demora, aerolíneas, aeropuertos, tiempos operacionales y cancelaciones.	La solución será un dashboard analítico que permita visualizar patrones de puntualidad, causas de retraso, concurrencia y rutas con problemas, entre otros, siendo un consolidado de los problemas encontrados en los vuelos.	<ul style="list-style-type: none"> Porcentaje de vuelos puntuales Porcentaje de desvíos Porcentaje de cancelación Porcentaje de desvíos Porcentaje de vuelos con retraso 	<p>Las acciones derivadas del dashboard permitirán identificar patrones, segmentar aerolíneas y aeropuertos y visualizar horarios o rutas vulnerables para realizar mejores planificaciones en el tráfico aéreo</p>	
	Hipótesis <ul style="list-style-type: none"> Algunas aerolíneas son más puntuales que otras. NAS y LateAircraftDelay serán las causas dominantes. Aeropuertos de alta concurrencia tendrán más retrasos. Algunas rutas presentan más cancelaciones y desvíos 	Actores <ul style="list-style-type: none"> Cliente general: Entidades reguladoras de vuelos/tráfico aéreo Stakeholders: Aerolíneas, aeropuertos, reguladores. Usuarios: Analistas e investigadores Impacto en: planificación, eficiencia operativa y experiencia del pasajero. 			
Valores / Riesgos		Rendimiento / Impacto			
El resultado aportará un gran valor al generar visibilidad sobre la puntualidad y causas de demora. Los riesgos se encuentran en los límites que pueda dar el dataset debido a la falta de datos externos.		Capacidad de incrementar la tasa de vuelos puntuales, reducir el número de vuelos cancelados, entender cómo reducir la variabilidad entre tiempos programados y reales.			




Data Understanding

Descarga del dataset usando la interfaz BTS.
Columnas seleccionadas y justificación.
Exploración y análisis inicial (EDA).
Detección de valores faltantes y outliers.

Categoría	Nombre del campo	Nombre en Dataset	Justificación
Time Period	Year	YEAR	
	Month	MONTH	
	DayofMonth	DAY_OF_MONTH	Necesario para los filtros a implementar en el data product (dashboard) lo cual permitirá analizar y visualizar temporalidad de los vuelos
	DayOfWeek	DAY_OF_WEEK	
Airline	Reporting_Airline	OP_UNIQUE_CARRIER	Campo clave para medir y comparar la tasa de puntualidad, eficiencia operativa y cantidad de vuelos entre aerolíneas. Permite responder que compañías presentan mejor desempeño general.
Origin	OriginAirportID	ORIGIN_AIRPORT_ID	Identificador único del aeropuerto de salida. Permite establecer relaciones entre aeropuertos y rutas dentro del modelo en estrella y comparar desempeño por ubicación.
	OrigenCityMarketID	ORIGIN_CITY_MARKET_ID	Agrupa aeropuertos por ciudad, lo que facilita análisis a nivel de ciudad.
	Origin	ORIGIN	Código IATA del aeropuerto de salida. Facilita la identificación geográfica y visualización de rutas en dashboards o mapas.
	OriginCityName	ORIGIN_CITY_NAME	Proporciona el nombre de la ciudad asociada al aeropuerto, lo que permite contextualizar los resultados geográficamente.
Destination	OriginState	ORIGIN_STATE_ABR	Código del estado. Facilita el análisis por región y comparaciones de desempeño de rutas o concurrencia de uso.
	OriginStateName	ORIGIN_STATE_NM	Proporciona el nombre del estado asociada al aeropuerto, lo que permite contextualizar los resultados geográficamente.
	DestAirportID	DEST_AIRPORT_ID	Identificador único del aeropuerto de llegada. Permite analizar eficiencia en el destino, frecuencia de vuelos y rutas con mayor congestión o demoras.
	DestCityMarketID	DEST_CITY_MARKET_ID	Relaciona vuelos a nivel de mercado de ciudad destino, útil para analizar rutas metropolitanas y volumen de tráfico aéreo interurbano.
Dest	Dest	DEST	Código IATA del aeropuerto destino, fundamental para mapear rutas aéreas y analizar la conexión entre origen-destino.
	DestCityName	DEST_CITY_NAME	Permite visualizar y agrupar resultados por ciudad destino, útil para dashboards geográficos y reportes de movilidad.
	DestState	DEST_STATE_ABR	Código del estado. Facilita el análisis por región y comparaciones de desempeño de rutas o concurrencia de uso.
	DestStateName	DEST_STATE_NM	Proporciona el nombre del estado asociada al aeropuerto, lo que permite contextualizar los resultados geográficamente.

Resumen



EDA + Resumen + Graficas.ipynb

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

Comandos Código Texto Ejecutar todo

Índice

COMPRESIÓN DEL NEGOCIO

Descripción del Dataset

Inspiración del Análisis

2.1. EXPLORACIÓN DE DA...

Características derivad...

2.2. VISUALIZACIÓN DE D...

2.3 Resumen de calidad de da...

+ Sección

1. COMPRENSIÓN DEL NEGOCIO

Se definen los objetivos y el problema que se quiere resolver con los datos. Ejemplo: Una tienda online quiere predecir qué clientes harán compras recurrentes. Tareas clave: Identificar los objetivos de negocio. Establecer KPIs para medir el éxito del modelo.

1. CONOCIMIENTO DEL NEGOCIO

El presente proyecto se desarrolla a partir de un conjunto de datos relacionados con operaciones aéreas en Estados Unidos, específicamente vuelos comerciales. El dataset original contiene varios millones de registros; sin embargo, debido a limitaciones de memoria y para trabajar con datos representativos, se realizó un muestreo estratificado por año, seleccionando 200,000 vuelos por cada período, con el fin de mantener la distribución temporal y operacional del fenómeno.


El resultado final del muestreo contiene aproximadamente 2750000 registros (la misma cantidad por cada año) y las siguientes variables seleccionadas por su relevancia analítica y su valor para los procesos posteriores de limpieza, preparación, modelado y visualización.

Descripción del Dataset


Las columnas elegidas corresponden a las categorías sugeridas por el catedrático:

- Time Period
- Airline
- Origin and Destination
- Departure & Arrival Performance
- Cancellations & Diversions
- Flight Summaries
- Cause of Delay
- A partir de estas categorías, las variables incluidas en el dataset final son:

Gráficas exploratorias



MAPA CONCEPTUAL



```
-- Creacion de dimension para dias festivos
CREATE TABLE dim_dias_festivos (
    festivo_id INT IDENTITY(1,1) PRIMARY KEY,
    fecha DATE NOT NULL UNIQUE,
    mes INT NOT NULL,
    dia INT NOT NULL,
    descripcion VARCHAR(100) NOT NULL
);

INSERT INTO dim_dias_festivos (fecha, mes, dia, descripcion)
VALUES
('2024-01-01', 1, 1, 'Año Nuevo'),
('2024-05-01', 5, 1, 'Día del Trabajo'),
('2024-06-30', 6, 30, 'Día del Ejército'),
('2024-09-15', 9, 15, 'Día de la Independencia'),
('2024-10-20', 10, 20, 'Revolución'),
('2024-11-01', 11, 1, 'Día de Todos los Santos'),
('2024-12-24', 12, 24, 'Nochebuena'),
('2024-12-25', 12, 25, 'Navidad'),
('2024-12-31', 12, 31, 'Año Viejo');

-- Adicion de nuevas columnas a la tabla de hechos
ALTER TABLE fact_flights ADD
    retraso_total INT NULL,
    semana INT NULL,
    trimestre INT NULL,
    dia_festivo INT NULL;

ALTER TABLE fact_flights
ADD CONSTRAINT FK_fact_festivo
FOREIGN KEY (dia_festivo)
REFERENCES dim_dias_festivos(festivo_id);

-- Creacion de valores derivados
UPDATE fact_flights
SET retraso_total = ISNULL(retraso_salida, 0) + ISNULL(retraso_llegada, 0);

UPDATE f
SET semana = DATEPART(WEEK, d.full_date)
FROM fact_flights f
JOIN dim_date d ON f.fecha_id = d.date_id;

UPDATE f
SET trimestre = DATEPART(QUARTER, d.full_date)
FROM fact_flights f
JOIN dim_date d ON f.fecha_id = d.date_id;
```

Data preparation

- Limpieza (duplicados, nulos, formatos de fecha).
- Estandarización de zonas horarias.
- Creación de columnas derivadas:
- **retraso_total**
- **categoría de retraso**
- **semana, trimestre, día festivo**
- **Integración de tablas externas**

```
from datetime import datetime
import pandas as pd
import pyodbc
import warnings

# =====
# === CONFIGURACIÓN
# =====

warnings.filterwarnings("ignore", category=UserWarning)

airlines_csv = r"datos/aerolineas.csv"
flights_csv = r"datos/vuelos.csv" # archivo de 10GB

chunk_size = 500_000 # medio millón de filas por chunk

connection_string = (
    "Driver={ODBC Driver 17 for SQL Server};"
    "Server=localhost;"
    "Database=DWBTS;"
    "Trusted_Connection=yes;"
)

conn = pyodbc.connect(connection_string)
cursor = conn.cursor()

# =====
# === CARGAR DIMENSION AEROLÍNEAS (ya es pequeño, se queda igual)
# =====
```



Modeling

```
--CREATE DATABASE DWBTS;

--USE DWBTS;

CREATE TABLE dim_airline (
    airline_id INT IDENTITY(1,1) PRIMARY KEY,
    code VARCHAR(10),
    description VARCHAR(200)
);


CREATE TABLE dim_date (
    date_id INT IDENTITY(1,1) PRIMARY KEY,
    year INT NOT NULL,
    month INT NOT NULL,
    day_of_month INT NOT NULL,
    day_of_week INT NOT NULL,
    full_date DATE NOT NULL
);

CREATE TABLE dim_airport (
    airport_id INT IDENTITY(1,1) PRIMARY KEY,
    code VARCHAR(10) NOT NULL,
    city_name VARCHAR(100),
    state_name VARCHAR(100)
);

CREATE TABLE fact_flights (
    flight_id BIGINT IDENTITY(1,1) PRIMARY KEY,
    airline_id INT NOT NULL,
    origin_airport_id INT NOT NULL,
    destination_airport_id INT NOT NULL,
    fecha_id INT NOT NULL,
    retraso_salida INT,
    retraso_llegada INT,
    cancelado BIT,
    desviado BIT,
    carrier_delay INT,
    weather_delay INT,
    NAS_delay INT,
    ...
);

```

Modelo de estrella





Evaluation

- Informe de evaluación
- Matriz de evaluación
- Lista de mejoras




Informe de evaluación

1. Proposito
2. Hallazgos clave
3. Conclusión
4. Calidad y complitud del modelo
5. Coherencia entre KPIs del Dashboard y Datos Reales
6. Comparación vs. Objetivos del Business Understanding
7. Validación Cruzada por Roles (Cross-Checking)
8. Conclusión y Próximos Pasos

Lista de mejoras

1. Implementar filtros para outliers en KPIs
2. Automatización completa del proceso ETL
3. Integración de datos meteorológicos externos
4. Incluir datos de tráfico aéreo y control de espacio aéreo
5. Desarrollo de alertas proactivas en el dashboard
6. Optimización del modelo estrella para consultas avanzadas
7. Incorporar análisis predictivo con Machine Learning
8. Mejorar la visualización de KPIs en el dashboard
9. Implementar control de calidad automatizado en cada carga
10. Ampliar el período de análisis con datos más recientes



Matriz de evaluación

Indicador	Descripción	Método de Validación	Resultado	Comentarios
% Puntualidad	Porcentaje de vuelos cuya hora de llegada ARR_DELAY y salida DEP_DELAY superan los 0 minutos, agrupados por aerolínea.	Consulta directa SQL sobre la tabla fact_flights .	Exitoso	Los resultados coinciden con los valores mostrados en el dashboard. Se observa que algunos aeropuertos presentan salidas antes del horario programado, lo que explica ligeras variaciones negativas en los retrasos.
Distribución de retrasos	Análisis de la distribución de minutos de demora por causa: CarrierDelay , WeatherDelay , NASDelay , SecurityDelay y LateAircraftDelay .	Consulta directa SQL agregada por tipo de causa.	Exitoso	Los resultados concuerdan con el dashboard. Las mayores demoras se atribuyen a factores operativos de la aerolínea y demoras por aeronaves provenientes de vuelos anteriores.
Comparación programado vs. real	Porcentaje de vuelos cuya hora de llegada ARR_DELAY y salida DEP_DELAY superan los 0 minutos, agrupados por aeropuerto.	Conteo y comparación directa de registros con ARR_DELAY > 0 y DEP_DELAY > 0 .	Atípico	Se identificaron valores extremos con retrasos de varias horas, atribuibles a condiciones operativas o climatológicas.
Ranking de aerolíneas	Ordenamiento de aerolíneas según el volumen de vuelos registrados y su desempeño promedio en puntualidad.	Agregación por tipo de demora y conteo total de vuelos.	Exitoso	Los resultados reflejan correctamente el ranking, destacando a Southwest Airlines Co. como la aerolínea con mayor número de operaciones y posicionamiento principal en el análisis.
Total de cancelaciones y desvíos	Conteo de vuelos cancelados (CANCELLED = 1) y desviados (DIVERTED = 1) según los registros del modelo.	Conteo simple y validación de totales.	Exitoso	Los valores del dashboard coinciden con los obtenidos mediante consulta directa. No se identificaron inconsistencias entre las métricas agregadas y los datos fuente.



Deployment

■ Manual Tecnico

■ Repositorio GitHub

■ Dashboard

MANUAL TÉCNICO



IntroduccionAnalisisDatos_ProyectoFinal Public

Issues Pull requests Actions Projects Security Insights

main 1 Branch 0 Tags

LuisCulajay	estructura final del proyecto
1_business_understanding	estructura final del proyecto
2_data_understanding	estructura final del proyecto
3_data_preparation	estructura final del proyecto
4_modeling	estructura final del proyecto
5_evaluation	estructura final del proyecto
6_deployment	estructura final del proyecto
datos	f2 a f6
entregables_finales	estructura final del proyecto
.gitignore	estructura final del proyecto
Enunciado.pdf	estructura final del proyecto
README.md	Initial commit

Elemento	Descripción
Nombre del Proyecto:	Análisis de Desempeño y Retrasos en Vuelos de EE.UU. (2011–2021)
Metodología aplicada:	CRISP-DM
Herramientas principales:	Python, SQL Server, Power BI, Docker
Equipo:	Data Administrator – Karen Morales Data Engineer – Luis Culajay BI Analyst – Jhonatan Simon Data Analyst – Brandon Portillo

Fecha


1/1/2011

12.00 mill.

Total de vuelos

- Aerolínea
- Altair Airlines Inc.
 - Altus Airlines
 - Amerford Airways Inc.
 - America West Airlines...
 - Americair Inc.
 - American Air Transport
 - American Airlines Inc.
 - American Central Airli...
 - American Flag Airline...
 - American Flight Group

Distribución de retrasos


● Seguridad ● Tripulación ● Clima ● Aerolínea ● NAS

Aeropuerto


- Aberdeen
- Abilene
- Adak Island
- Aguadilla
- Akron
- Alamosa
- Albany
- Albuquerque
- Alexandria

Aerolinea	Descripcion	Puntualidad
UA	United Air Lines Inc.	7391228
NK	Spirit Air Lines	6242708
WN	Southwest Airlines Co.	30563424
OO	SkyWest Airlines Inc.	15300240
YX	Republic Airline	2397300
OH	PSA Airlines Inc.	2021464
YV	Mesa Airlines Inc.	6998192
B6	JetBlue Airways	10220716
QX	Horizon Air	277132
HA	Hawaiian Airlines Inc.	-28436
F9	Frontier Airlines Inc.	3354304
MQ	Envoy Air	4976516
9E	Endeavor Air Inc.	-2511368
Total		113804532

29 mil

Vuelos desviados


Programado vs Real (Llegada)




193 mil

Vuelos cancelados


Programado vs Real (Salida)



Ranking de aerolíneas


● WN ● OO ● DL ● AA ● UA

Mapa geográfico por aeropuerto



Feedback



Muchas
gracias

GRUPO 3